전국 미세먼지 농도 예측모델 생성

충북대학교 산업인공지능학과 | 2025-2 어프렌티스프로젝트

〈튀김소보로 팀〉

목차

- 주제
- 데이터 수집
- 데이터 분석
- 데이터 전처리
- 모델 선정
- 모델 학습
- 모델 평가
- 결론
- 예측 비교
- 추가실험

1. 주제

겨울철마다 심해지는 고농도 미세먼지

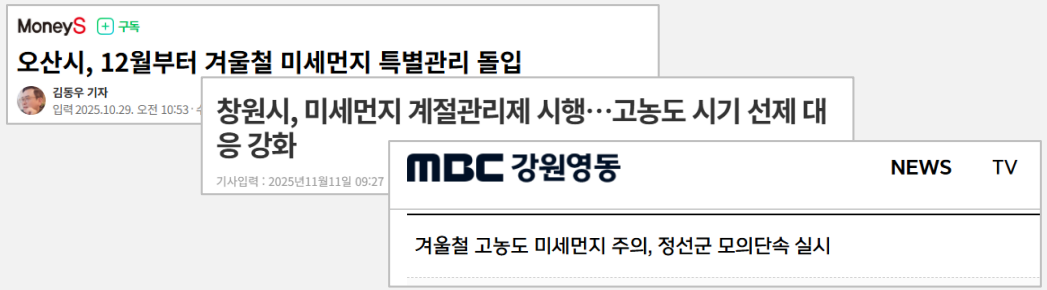

한국은 매년 겨울이 되면 대기 정체, 난방 증가, 외부 오염물질 유입 등의 영향으로 고농도 미세먼지 현상이 반복적으로 발생하는 문제가 있다. 이로 인해 호흡기 질환 증가, 대기질 악화, 사회적 비용 증가 등 다양한 문제가 초래된다.

정확한 미세먼지 예측을 통한 대비책 마련 필요

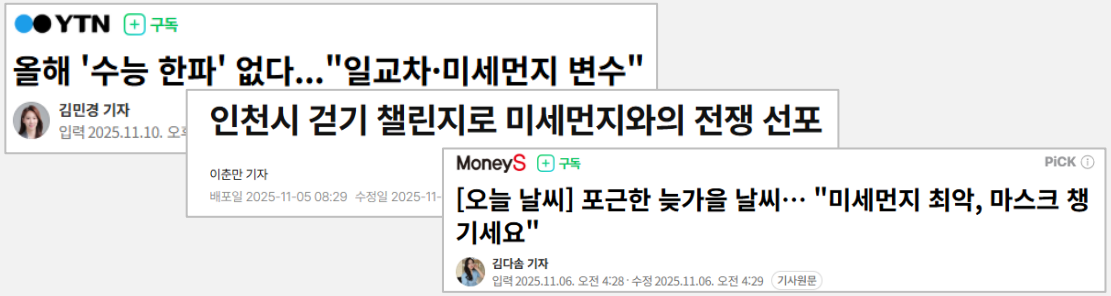

미세먼지는 예측의 정확도에 따라 개인적, 사회적 대응 수준이 달라진다. 미세먼지 농도 변화에 따라 사람들의 외출, 야외활동 등을 조정 할 수 있음은 물론 생활 전반적으로 안전과 효율을 높일 수 있다.

미세먼지 발생의 원인을 기상·환경 데이터를 통해 정량적으로 분석하고
시기별 특징을 파악하여 전국 단위 미세먼지 예측 모델을 구축함으로써 정확한 대기질 정보를 제공하고자 한다.

미세먼지의 농도를 미리 예측하여 대비함으로써
건강, 환경 정책 등에 긍정적인 영향을 줄 수 있도록 함

2. 데이터 수집

데이터 수집

date	측정망	측정소명	1시	2시	3시	4시	5시	6시	7시	8시	9시	10시	11시	12시	13시	14시	15시	16시	17시	18시	19시	20시	21시	22시	23시	24시
2024-01-01	도시대기	[서울 강남구]강남구	28	22	21	23	25	24	26	25	25	23	23	17	20	21	20	21	21	20	23	21	23	27	38	40
2024-01-01	도시대기	[서울 강동구]강동구	22	17	20	21	21	19	25	22	20	19	17	16	-	16	14	13	15	-	25	26	25	26	-	37
2024-01-01	도시대기	[서울 강북구]강북구	14	15	16	14	16	17	17	20	21	16	22	15	19	21	22	22	21	18	20	17	22	24	28	32
2024-01-01	도시대기	[서울 강서구]강서구	41	43	53	47	45	31	29	22	27	16	22	17	19	19	19	19	21	18	28	26	34	33	38	37
2024-01-01	도시대기	[서울 관악구]관악구	48	46	54	45	42	35	30	26	28	29	28	25	32	26	21	25	27	28	27	32	34	36	46	47
2024-01-01	도시대기	[서울 광진구]광진구	22	17	17	16	19	17	16	16	18	15	12	14	18	22	20	18	17	20	22	21	23	25	29	36
2024-01-01	도시대기	[서울 구로구]구로구	45	43	37	46	37	30	27	26	28	30	32	24	27	16	17	21	26	22	23	28	-	37	38	44
2024-01-01	도시대기	[서울 금천구]금천구	34	31	31	31	33	30	30	28	28	32	34	30	27	27	15	21	20	25	27	24	28	29	35	36
2024-01-01	도시대기	[서울 노원구]노원구	26	22	28	28	28	21	21	20	25	18	19	22	16	23	23	23	25	24	30	26	29	29	33	35
2024-01-01	도시대기	[서울 도봉구]도봉구	16	23	-	19	21	21	-	-	13	-	19	15	16	16	16	-	17	19	15	20	-	-	30	-
2024-01-01	도시대기	[서울 동대문구]동대문구	26	24	25	27	28	25	24	18	20	20	20	19	23	21	21	19	18	20	22	23	25	28	35	38
2024-01-01	도시대기	[서울 동작구]동작구	38	39	41	37	37	33	30	24	26	25	23	20	23	19	21	19	20	22	24	22	22	25	30	36
2024-01-01	도시대기	[서울 마포구]마포구	32	31	33	26	28	23	-	-	-	22	27	25	24	20	20	17	20	18	23	23	26	-	-	-
2024-01-01	도시대기	[서울 서대문구]서대문구	-	28	24	25	-	17	18	16	18	17	15	16	19	20	19	18	20	23	24	27	30	34	37	37
2024-01-01	도시대기	[서울 서초구]서초구	35	37	-	31	30	30	24	27	32	28	26	26	25	24	20	17	22	26	21	24	28	34	36	42

date	측정망	측정소명	1시	2시	3시	4시	5시	6시	7시	8시	9시	10시	11시	12시	13시	14시	15시	16시	17시	18시	19시	20시	21시	22시	23시	24시
2024-01-01	교외대기	[충북 괴산군]청천면	34	28	30	35	31	25	23	22	24	27	24	21	20	20	19	17	26	31	40	35	31	30	30	36
2024-01-01	교외대기	[충북 음성군]금왕	49	48	47	38	39	41	43	43	39	43	40	33	43	42	45	43	48	50	49	51	59	65	67	77
2024-01-01	도시대기	[충북 괴산군]감물면	40	30	28	24	32	29	27	23	25	17	20	27	23	25	21	18	23	23	22	21	27	32	24	25
2024-01-01	도시대기	[충북 괴산군]괴산읍	26	26	35	27	30	24	32	25	27	25	21	20	18	18	20	20	18	25	23	23	14	22	22	24
2024-01-01	도시대기	[충북 단양군]단성면	21	22	23	26	28	26	25	26	24	26	29	41	41	46	31	25	40	46	27	23	21	22	23	27
2024-01-01	도시대기	[충북 단양군]단양읍	21	21	22	22	20	25	26	27	26	27	25	21	26	25	19	22	23	17	22	18	19	17	18	16
2024-01-01	도시대기	[충북 단양군]매포읍	26	24	22	24	31	33	43	40	39	42	78	81	92	60	40	39	38	45	31	31	34	28	28	31
2024-01-01	도시대기	[충북 보은군]보은읍	31	27	24	25	27	20	14	16	12	13	12	14	16	12	16	17	13	19	18	20	27	29	25	23
2024-01-01	도시대기	[충북 영동군]영동읍	25	28	27	29	37	30	32	23	17	16	17	14	17	12	17	13	11	18	27	27	31	27	29	28
2024-01-01	도시대기	[충북 영동군]황간면	17	22	18	21	21	18	23	24	15	17	19	14	19	17	16	15	16	19	23	22	18	24	21	23
2024-01-01	도시대기	[충북 옥천군]옥천읍	28	25	29	26	24	24	26	21	13	13	16	15	16	21	18	12	14	15	24	30	28	22	23	14
2024-01-01	도시대기	[충북 음성군]소이면	32	31	32	33	21	23	23	28	27	24	24	24	25	28	26	21	21	27	21	30	31	27	34	31
2024-01-01	도시대기	[충북 음성군]음성읍	30	26	32	37	23	28	27	28	27	25	25	25	21	17	19	22	24	22	24	31	30	29	31	27

출처 : airkorea - **PM10**,PM2.5

- 에어코리아 지역, 시간별 미세먼지 데이터 수집.

airkorea_02_2024-01-01_2025-11-26.csv
airkorea_031_2024-01-01_2025-11-26.csv
airkorea_032_2024-01-01_2025-11-26.csv
airkorea_033_2024-01-01_2025-11-26.csv
airkorea_041_2024-01-01_2025-11-26.csv
airkorea_042_2024-01-01_2025-11-26.csv
airkorea_043_2024-01-01_2025-11-26.csv

- https://www.airkorea.or.kr/web/pmRelaySub 측정소 및 일자별 데이터 크롤링
- 2024-01-01 ~ 2025-11-26 까지의 전국 대기측정소 데이터

3. 데이터 분석

데이터 구조 분석

	date	측정망	측정소명	1시	2시	3시	4시	5시	6시	7시	...	17시	18시	19시	20시	21시	22시	23시	24시
0	2024-01-01	도시대기	[대전 대덕구]문평동	30	32	36	28	35	30	31	...	21	24	19	24	27	26	27	30
1	2024-01-01	도시대기	[대전 대덕구]읍내동	33	32	29	26	23	25	26	...	8	11	16	15	17	22	19	17
2	2024-01-01	도시대기	[대전 동구]대성동	22	23	26	21	23	18	20	...	15	19	12	16	21	20	20	19
3	2024-01-01	도시대기	[대전 동구]성남동1	27	32	37	33	27	26	29	...	22	20	22	26	27	26	24	25
4	2024-01-01	도시대기	[대전 서구]둔산동	31	34	36	30	26	29	28	...	-	22	21	22	19	26	27	23
5	2024-01-01	도시대기	[대전 서구]정림동	25	35	37	36	35	28	33	...	15	15	20	18	20	23	24	21
6	2024-01-01	도시대기	[대전 유성구]관평동	30	34	28	27	27	29	32	...	25	25	23	28	25	30	26	23
7	2024-01-01	도시대기	[대전 유성구]구성동	28	29	26	27	33	29	28	...	22	20	17	20	26	25	29	24
8	2024-01-01	도시대기	[대전 유성구]노은동	34	29	22	24	30	27	30	...	15	20	24	22	19	26	20	21
9	2024-01-01	도시대기	[대전 유성구]상대동(대전)	32	25	24	20	23	23	25	...	21	17	19	21	24	22	23	26
10	2024-01-01	도시대기	[대전 중구]문창동	29	27	27	27	24	23	23	...	13	12	16	20	15	16	13	16
11	2024-01-01	도로변대기	[대전 서구]월평동	29	31	37	38	31	33	32	...	12	19	18	26	25	28	28	25
12	2024-01-01	도로변대기	[대전 유성구]지족동	-	-	-	-	-	-	-	...	-	-	-	-	-	-	-	-
13	2024-01-01	도로변대기	[대전 중구]대흥동1	27	30	30	30	29	31	28	...	45	41	48	29	33	36	31	29
14	2024-01-02	도시대기	[대전 대덕구]문평동	26	24	27	24	24	30	26	...	46	48	49	46	48	48	49	50

- 시간별 데이터가 1시, 2시, ··· 24시처럼 가로(wide) 형태로 존재.
- 결측치가 '–' 등 문자로 포함됨.
- 측정소 정보가 여러 컬럼(지점ID, 측정소명, 지점 등)에 흩어져 있음.
- 예측 모델에 필요한 시계열 정보(lag, rolling) 부재.

Lag : 즉각적인 영향을 반영하기 위한 이전 시점의 값
Rolling : 노이즈 제거 및 추세 반영을 위한 이전 시점의 이동평균

4. 데이터 전처리

데이터 구조 변환 및 보간

- 데이터를 date, station, hour, pm10 형태로 역피봇
- 결측치 보간, 시간단위 = “1시”->1 int 변환
- 3시 값이 비어있는 경우 2시->4시 사이 데이터의 평균값을 넣어 결측 보완

날짜 기반 파생 변수 생성

- 모델이 계절·요일 패턴을 학습할 수 있도록 다음 변수 생성
- 계절성·요일성 반영

Ex)

month (월)
day (일)
weekday (요일)
is_weekend (주말 여부)

시계열 특징(lag/rolling) 생성

- 미세먼지 농도는 직전 시간 농도에 강하게 의존하여 측정소 별 lag/rolling 생성

Ex)

직전 관측값

- lag1 : 1시간 전 데이터
- lag24 : 24시간 전 데이터

이동평균(rolling features)

- rolling3 : 최근 3시간 평균
- rolling24 : 최근 24시간 평균

유효데이터 필터링 및 정규화

- lag1이 존재하는 데이터만 사용
- 주말, lag, rolling, 요일 등의 int data

4. 데이터 전처리

데이터 전처리 결과

	date	측정망	측정소명	지점 ID	지점	hour	pm10	station	month	day	weekday	is_weekend	lag1	lag24	rolling3	rolling24
0	2024-01-01	항만	[강원 강릉시]옥계항	NaN	NaN	2	24.0	[강원 강릉시] 옥계항	-1.589802	-1.669345	-1.493752	-0.631996	-0.260484	7.180710e-15	-0.266861	-0.308027
1	2024-01-01	항만	[강원 강릉시]옥계항	NaN	NaN	3	24.0	[강원 강릉시] 옥계항	-1.589802	-1.669345	-1.493752	-0.631996	-0.260484	7.180710e-15	-0.266861	-0.308027
2	2024-01-01	항만	[강원 강릉시]옥계항	NaN	NaN	4	24.0	[강원 강릉시] 옥계항	-1.589802	-1.669345	-1.493752	-0.631996	-0.260484	7.180710e-15	-0.266861	-0.308027
3	2024-01-01	항만	[강원 강릉시]옥계항	NaN	NaN	5	24.0	[강원 강릉시] 옥계항	-1.589802	-1.669345	-1.493752	-0.631996	-0.260484	7.180710e-15	-0.266861	-0.308027
4	2024-01-01	항만	[강원 강릉시]옥계항	NaN	NaN	6	24.0	[강원 강릉시] 옥계항	-1.589802	-1.669345	-1.493752	-0.631996	-0.260484	7.180710e-15	-0.266861	-0.308027
5	2024-01-01	항만	[강원 강릉시]옥계항	NaN	NaN	7	24.0	[강원 강릉시] 옥계항	-1.589802	-1.669345	-1.493752	-0.631996	-0.260484	7.180710e-15	-0.266861	-0.308027
6	2024-01-01	항만	[강원 강릉시]옥계항	NaN	NaN	8	24.0	[강원 강릉시] 옥계항	-1.589802	-1.669345	-1.493752	-0.631996	-0.260484	7.180710e-15	-0.266861	-0.308027
7	2024-01-01	항만	[강원 강릉시]옥계항	NaN	NaN	9	24.0	[강원 강릉시] 옥계항	-1.589802	-1.669345	-1.493752	-0.631996	-0.260484	7.180710e-15	-0.266861	-0.308027

±3 범위로 스케일링

5. 모델 선정

- 미세먼지 농도 예측 모델 선정

Regression

Supervised Learning

- Classification
  - Sample을 몇 개의 Class로 분류하는 방식
- Regression
  - 임의의 어떤 숫자를 예측하는 방식

시간, 지역 조건에서 연속형 수치를 예측 => Regression(회귀)으로 정의

Linear Regression

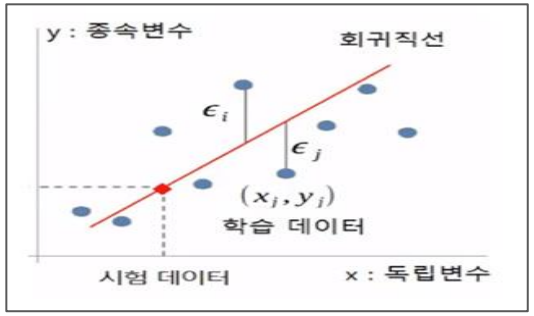

미세먼지 농도 y와 독립변수-지역, 시간 x의 선형관계 모델링 => Linear Regression(선형회귀)로 예측 모델 생성

5. 모델 선정

- **미세먼지 농도 예측 모델 선정**

시계열 전처리 기반의 feature가 잘 구성된 경우, 선형 회귀 모델은 예측력 대비 계산 효율이 매우 높아 Linear Regression을 우선적인 baseline으로 선정
Regularized Linear Regression(Ridge, Lasso)를 적용하여 비교 후 최종 모델 선정 필요

시계열 데이터 (lag/rolling) 과적합 문제

Linear Regression

Regularization 필요

Lasso

L1 정규화를 통해 일부 계수를 0으로 만들어 모델에서 무시하게 함으로써 모델의 주요 기능을 강조함

- L1 Regularization (ex: Lasso)

$$J(w) = Loss(w) + \frac{\lambda}{2} \times \frac{1}{n}\sum_{i=1}^{n}|w_i|$$

- L2 Regularization (ex: Ridge)

$$J(w) = Loss(w) + \frac{\lambda}{2} \times \frac{1}{n}\sum_{i=1}^{n}|w_i|^2$$

penalty term

Ridge

L2 정규화를 통해 모델의 가중치(계수) 크기를 작게 유지하려고 함
모델의 정확성을 높이려고 함

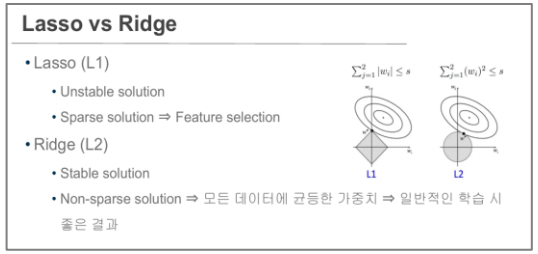

✓ **scikit-learn의 Linear Regession, Ridge, Lasso 예측성능 비교**

```python
models = {
    "LinearRegression": LinearRegression(),
    "Ridge(alpha=1.0)": Ridge(alpha=1.0),
    "Lasso(alpha=0.1)": Lasso(alpha=0.1, max_iter=10000),
}
```

6. 모델 학습

- **학습 데이터 구성**

Feature	Target
1. 시간 날짜 정보 : "hour", "month", "day", "weekday", "is_weekend“ 2. 시계열 정보 : "lag1", "lag24", "rolling3", "rolling24“ *이 중 대부분은 StandardScaler로 정규화 (hour는 원본 값 사용)	1. y_train = pm10 2. 각 시간대의 실제 미세먼지 농도 (시계열 레이블)

```
feature_cols = [
        "hour", "month", "day", "weekday", "is_weekend",
        "lag1", "lag24", "rolling3", "rolling24",
    ]
```

```
X_train = train[feature_cols]
y_train = train["pm10"]

X_test = test[feature_cols]
y_test = test["pm10"]
```

6. 모델 학습

- **학습 절차**

문제 정의	• 입력 특징 X: 전처리 및 특징 생성 결과(요일/시간대, lag/rolling) • 타깃 Y: PM10 실제 관측값
학습/검증 데이터 분리	• train : 과거 80% 날짜 구간 • test : 이후 20% 날짜 구간 *시계열 순서를 유지한 Train/Test Split -> 미래 데이터에 대한 예측 성능을 검증하기 위해 시계열 보존
동일 조건	• 동일한 전처리, feature, Train데이터 사용
모델 학습	• fit(X_train, y_train)으로 각 모델별 회귀 계수 학습 • 학습된 모델에 X_test를 넣어 y_pred(예측 PM10) 생성
검증	• R2, MAE, RMSE 검증지표를 통해 검증

7. 모델 평가

- **모델 평가**

평가지표		
구분	특징	
R2(결정계수)	• 모델이 실제값의 변동(분산)을 얼마나 설명했는가? • 1에 가까울 수록 좋음	전반적 설명력
MAE	• 예측 오차의 절대값 평균 • 실제값과 예측값이 평균적으로 얼마나 차이나는가? • 이상치에 RMSE보다 덜 민감하여 일반적인 오차크기를 확인하기 용이함	절대적 오차 크기 평가
RMSE	• 오차를 제곱하여 평균낸 값의 루트값 • 제곱으로 인해 큰 오차에 더 민감함	

7. 모델 평가

- **모델 평가**

```python
model.fit(X_train, y_train)
y_pred = model.predict(X_test)

r2  = r2_score(y_test, y_pred)
mae = mean_absolute_error(y_test, y_pred)

mse  = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)

results.append({
    "model": name,
    "R2": r2,
    "MAE": mae,
    "RMSE": rmse,
})
```

	model	R2	MAE	RMSE
1	Ridge(alpha=1.0)	0.915073	2.568711	4.360437
0	LinearRegression	0.915073	2.568712	4.360437
2	Lasso(alpha=0.1)	0.907412	2.676190	4.552872

Linear Regression **Ridge**

- ✓ R^2, MAE, RMSE가 거의 동일
- ✓ 데이터가 선형 구조를 잘 따르고 있어 규제로 계수를 조절하더라도 성능 차이가 거의 없음

두 모델 모두 안정적인 선형 예측 모델로 사용 가능

Lasso (α=0.1)

- ✓ R^2가 약간 낮고, MAE/RMSE도 조금 더 큼
- ✓ L1 정규화로 일부 feature 계수가 0에 가까워지면서 정보 손실 발생

변수 선택 효과는 있지만
수집 데이터에서는 성능이 다소 감소

8. 결론

- **모델 선택 기준**

- 높은 R^2 (설명력)
- 낮은 MAE/RMSE (실제 오차 크기)
- 계수 안정성 및 과적합 가능성

Ridge(α=1.0)

- LinearRegression과 동급의 성능($R^2 \approx 0.915$)
- L2 정규화로 계수가 안정적 → 과적합 위험 최소화
- 실제 서비스/실증 단계에서 사용하기에 가장 적합한 모델

LinearRegression

- 기본 Baseline 모델로 활용
- Ridge와 거의 동일 성능 → "정규화 전·후 비교용 기준 모델"

Lasso(α=0.1)

- 변수가 매우 많을 때는 유용
- 미세먼지 데이터셋에서 주요 feature까지 일부 약화되면서 성능이 다소 저하

전처리된 시계열·날짜 특성을 이용해 Linear, Ridge, Lasso 세 모델을 동일 조건에서 학습·검증한 결과
Ridge와 Linear가 가장 높은 설명력($R^2 \approx 0.915$)과 낮은 오차(RMSE≈4.36)를 보여 최종 예측 모델로 선택
Lasso는 변수 선택 효과는 있었으나, 본 데이터에서는 다소 성능 저하를 보임

9. 예측 비교

모델별 예측 비교 시각화 — 상위 300 구간

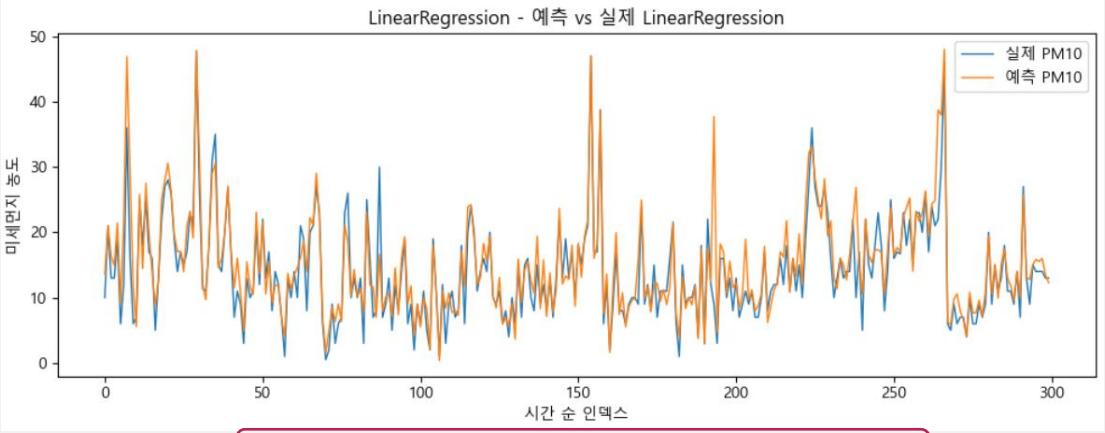

LinearRegression

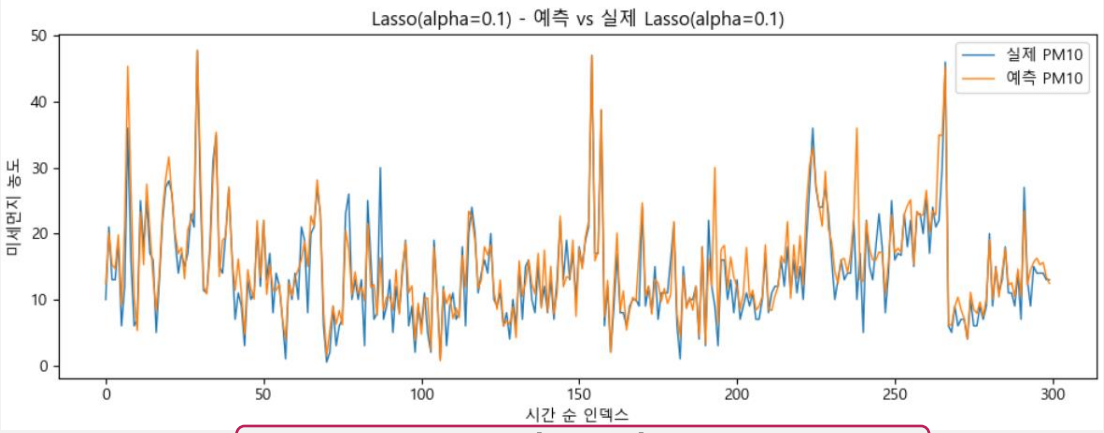

Lasso(α=0.1) – L1

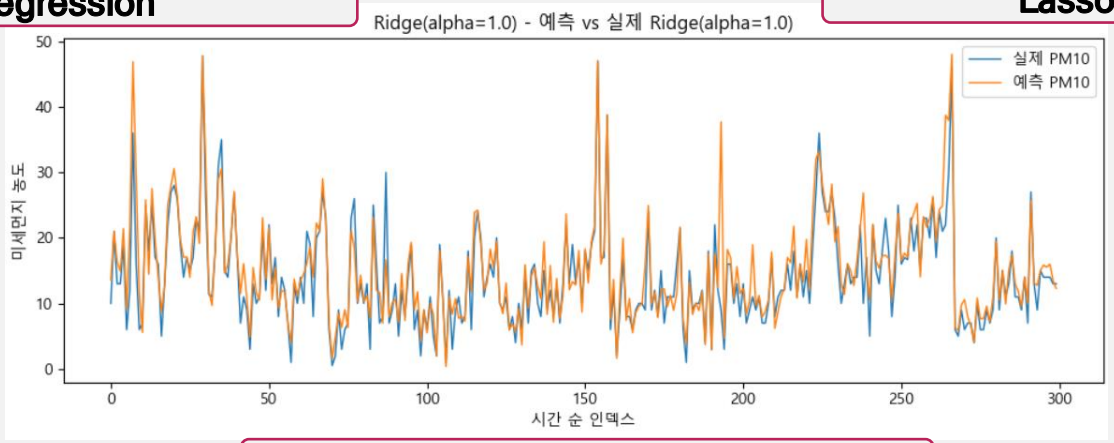

Ridge(α=1.0) – L2

9. 예측 비교

2025년 9월 23일 모델별 미세먼지 예측 비교

측정소 : "[대전 서구]월평동", "[대전 서구]둔산동","[충북 청주시]오창읍", "[충북 청주시]봉명동

```
*** 예측 Ridge(alpha=1.0) ***
측정소      : [대전 서구]월평동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 16.00
예측 PM10   : 11.67
오차(예측-실제) : -4.33
*** 예측 LinearRegression ***
측정소      : [대전 서구]월평동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 16.00
예측 PM10   : 11.67
오차(예측-실제) : -4.33
*** 예측 Lasso(alpha=0.1) ***
측정소      : [대전 서구]월평동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 16.00
예측 PM10   : 11.45
오차(예측-실제) : -4.55
```

```
*** 예측 Ridge(alpha=1.0) ***
측정소      : [대전 서구]둔산동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 6.00
예측 PM10   : 8.83
오차(예측-실제) : 2.83
*** 예측 LinearRegression ***
측정소      : [대전 서구]둔산동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 6.00
예측 PM10   : 8.83
오차(예측-실제) : 2.83
*** 예측 Lasso(alpha=0.1) ***
측정소      : [대전 서구]둔산동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 6.00
예측 PM10   : 9.18
오차(예측-실제) : 3.18
```

```
*** 예측 Ridge(alpha=1.0) ***
측정소      : [충북 청주시]오창읍
날짜/시간   : 2025-09-23 12시
실제 PM10   : 14.00
예측 PM10   : 12.72
오차(예측-실제) : -1.28
*** 예측 LinearRegression ***
측정소      : [충북 청주시]오창읍
날짜/시간   : 2025-09-23 12시
실제 PM10   : 14.00
예측 PM10   : 12.72
오차(예측-실제) : -1.28
*** 예측 Lasso(alpha=0.1) ***
측정소      : [충북 청주시]오창읍
날짜/시간   : 2025-09-23 12시
실제 PM10   : 14.00
예측 PM10   : 12.47
오차(예측-실제) : -1.53
```

```
*** 예측 Ridge(alpha=1.0) ***
측정소      : [충북 청주시]봉명동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 11.00
예측 PM10   : 14.81
오차(예측-실제) : 3.81
*** 예측 LinearRegression ***
측정소      : [충북 청주시]봉명동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 11.00
예측 PM10   : 14.81
오차(예측-실제) : 3.81
*** 예측 Lasso(alpha=0.1) ***
측정소      : [충북 청주시]봉명동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 11.00
예측 PM10   : 15.22
오차(예측-실제) : 4.22
```

9. 예측 비교

2025년 9월 23일 모델별 미세먼지 예측 비교

측정소 : "[대전 서구]월평동", "[대전 서구]둔산동","[충북 청주시]오창읍", "[충북 청주시]봉명동

	station	LinearRegression(RMSE)	Ridge(alpha=1.0)(RMSE)	Lasso(alpha=0.1)(RMSE)
0	[대전 서구]월평동	5.048329	5.048330	5.196951
1	[대전 서구]둔산동	6.206140	6.206139	6.481529
2	[충북 청주시]오창읍	5.132852	5.132852	5.307994
3	[충북 청주시]봉명동	4.946626	4.946627	5.111690

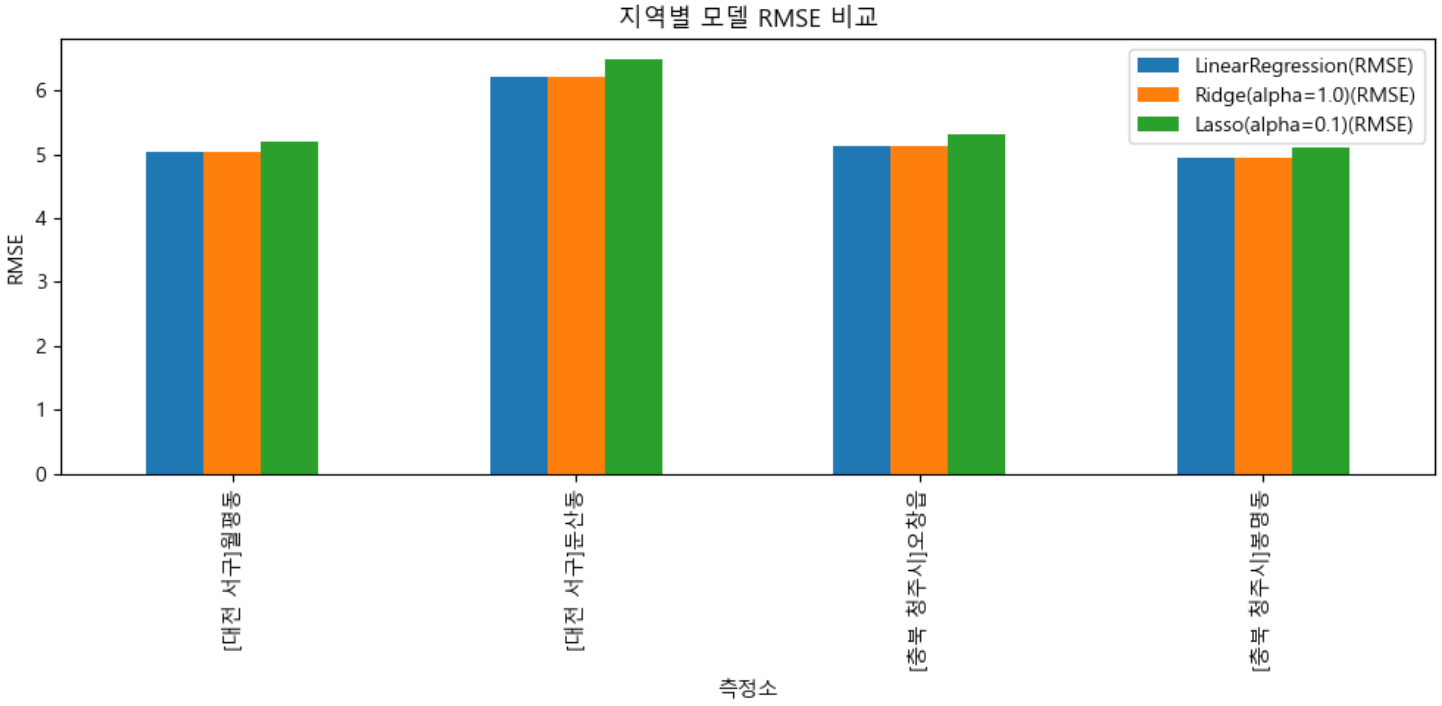

9. 예측 비교

실제 관측값과 모델 예측값의 시계열 비교 (Top 200 Hours) – 측정소: 대전 서구 둔산동

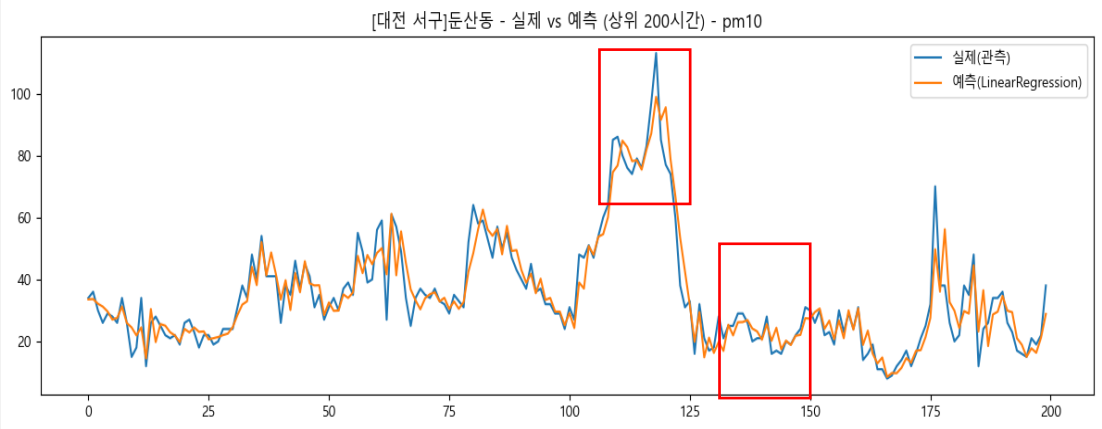

LinearRegression

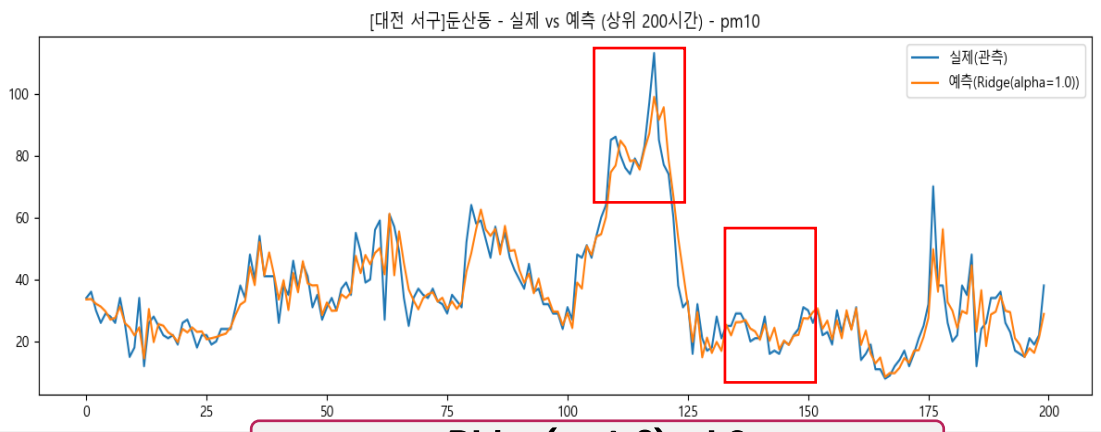

Ridge(α=1.0) – L2

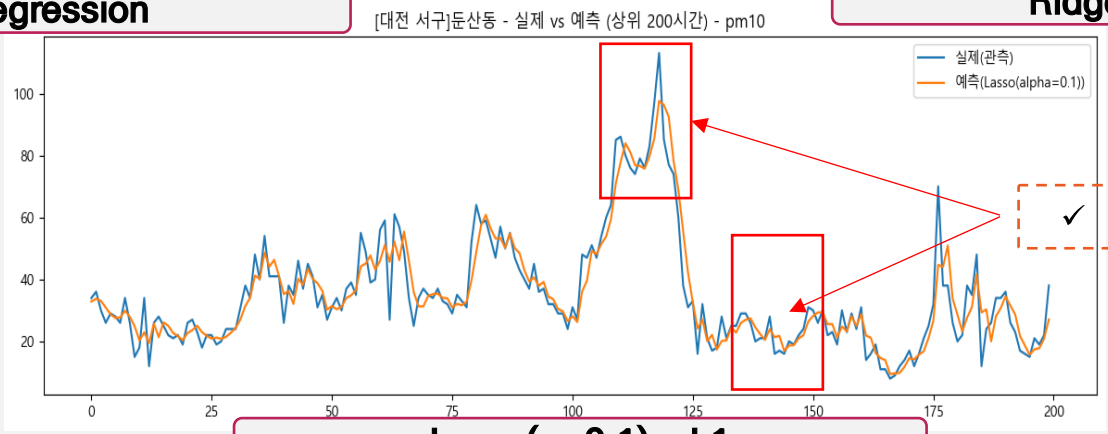

✓ Feature가 10개 이하로 적어 성능 감소

Lasso(α=0.1) – L1

10. 신경망 기반 회귀모델(추가 연구)

Model : sklearn.neural_network.MLPRegressor

- ✓ 은닉층 2개
- ✓ 각 층 64 노드
- ✓ 활성함수 ReLU
- ✓ Adam 옵티마이저
- ✓ early_stopping 사용

```
"LinearRegression": LinearRegression(),
"Ridge(alpha=1.0)": Ridge(alpha=1.0),
"Lasso(alpha=0.1)": Lasso(alpha=0.1, max_iter=10000),
"MLPRegressor(2x64)": MLPRegressor(
    hidden_layer_sizes=(64, 64),
    activation="relu",
    solver="adam",
    learning_rate_init=0.001,
    max_iter=50,
    early_stopping=True,
    random_state=42,
```

```
*** 예측 MLPRegressor(2x64) ***
측정소      : [대전 서구]월평동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 16.00
예측 PM10   : 11.54
오차(예측-실제) : -4.46
*** 예측 MLPRegressor(2x64) ***
측정소      : [대전 서구]둔산동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 6.00
예측 PM10   : 8.75
오차(예측-실제) : 2.75
*** 예측 MLPRegressor(2x64) ***
측정소      : [충북 청주시]오창읍
날짜/시간   : 2025-09-23 12시
실제 PM10   : 14.00
예측 PM10   : 12.57
오차(예측-실제) : -1.43
*** 예측 MLPRegressor(2x64) ***
측정소      : [충북 청주시]봉명동
날짜/시간   : 2025-09-23 12시
실제 PM10   : 11.00
예측 PM10   : 14.62
오차(예측-실제) : 3.62
```

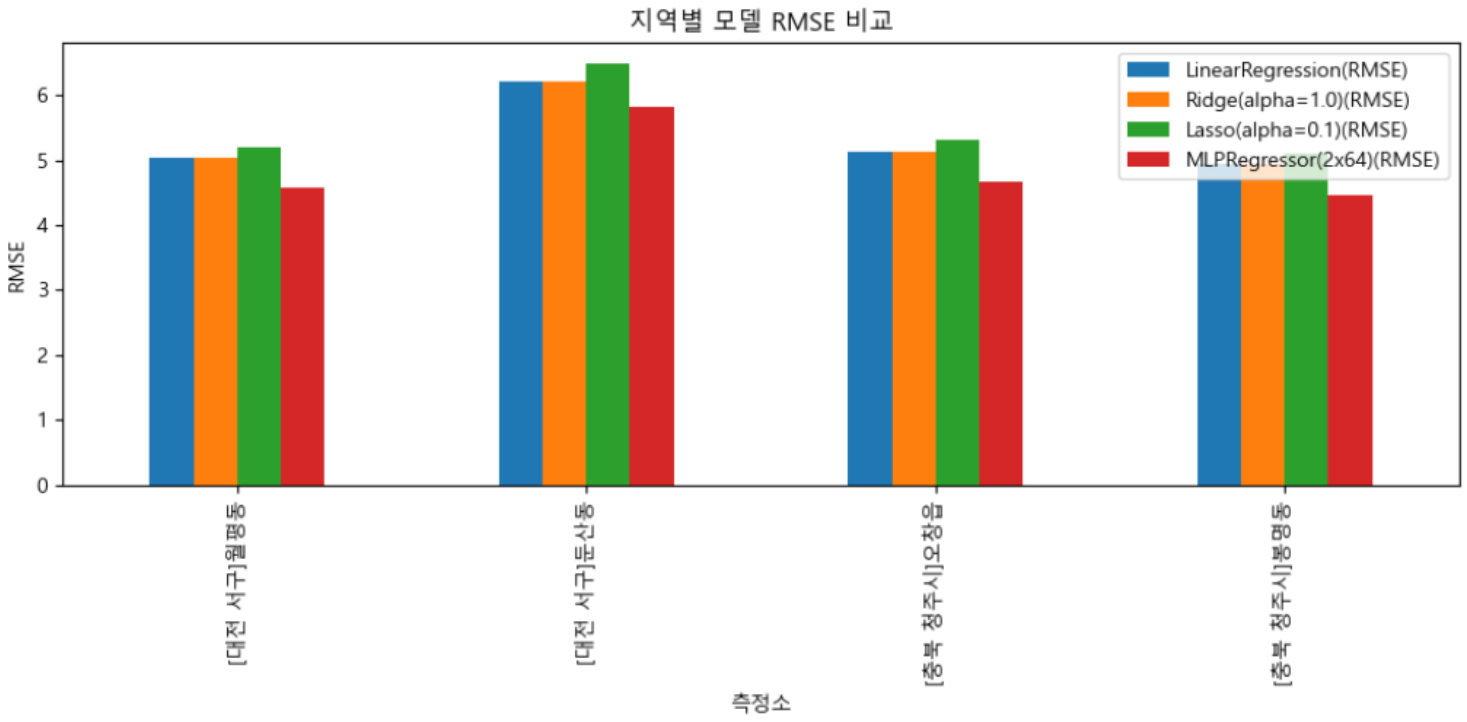

10. 신경망 기반 회귀모델(추가 연구)

관측 데이터의 패턴을 잘 따라가는 모습

[대전 서구] 둔산동 – 실제 vs 예측 (상위 200시간) – pm10

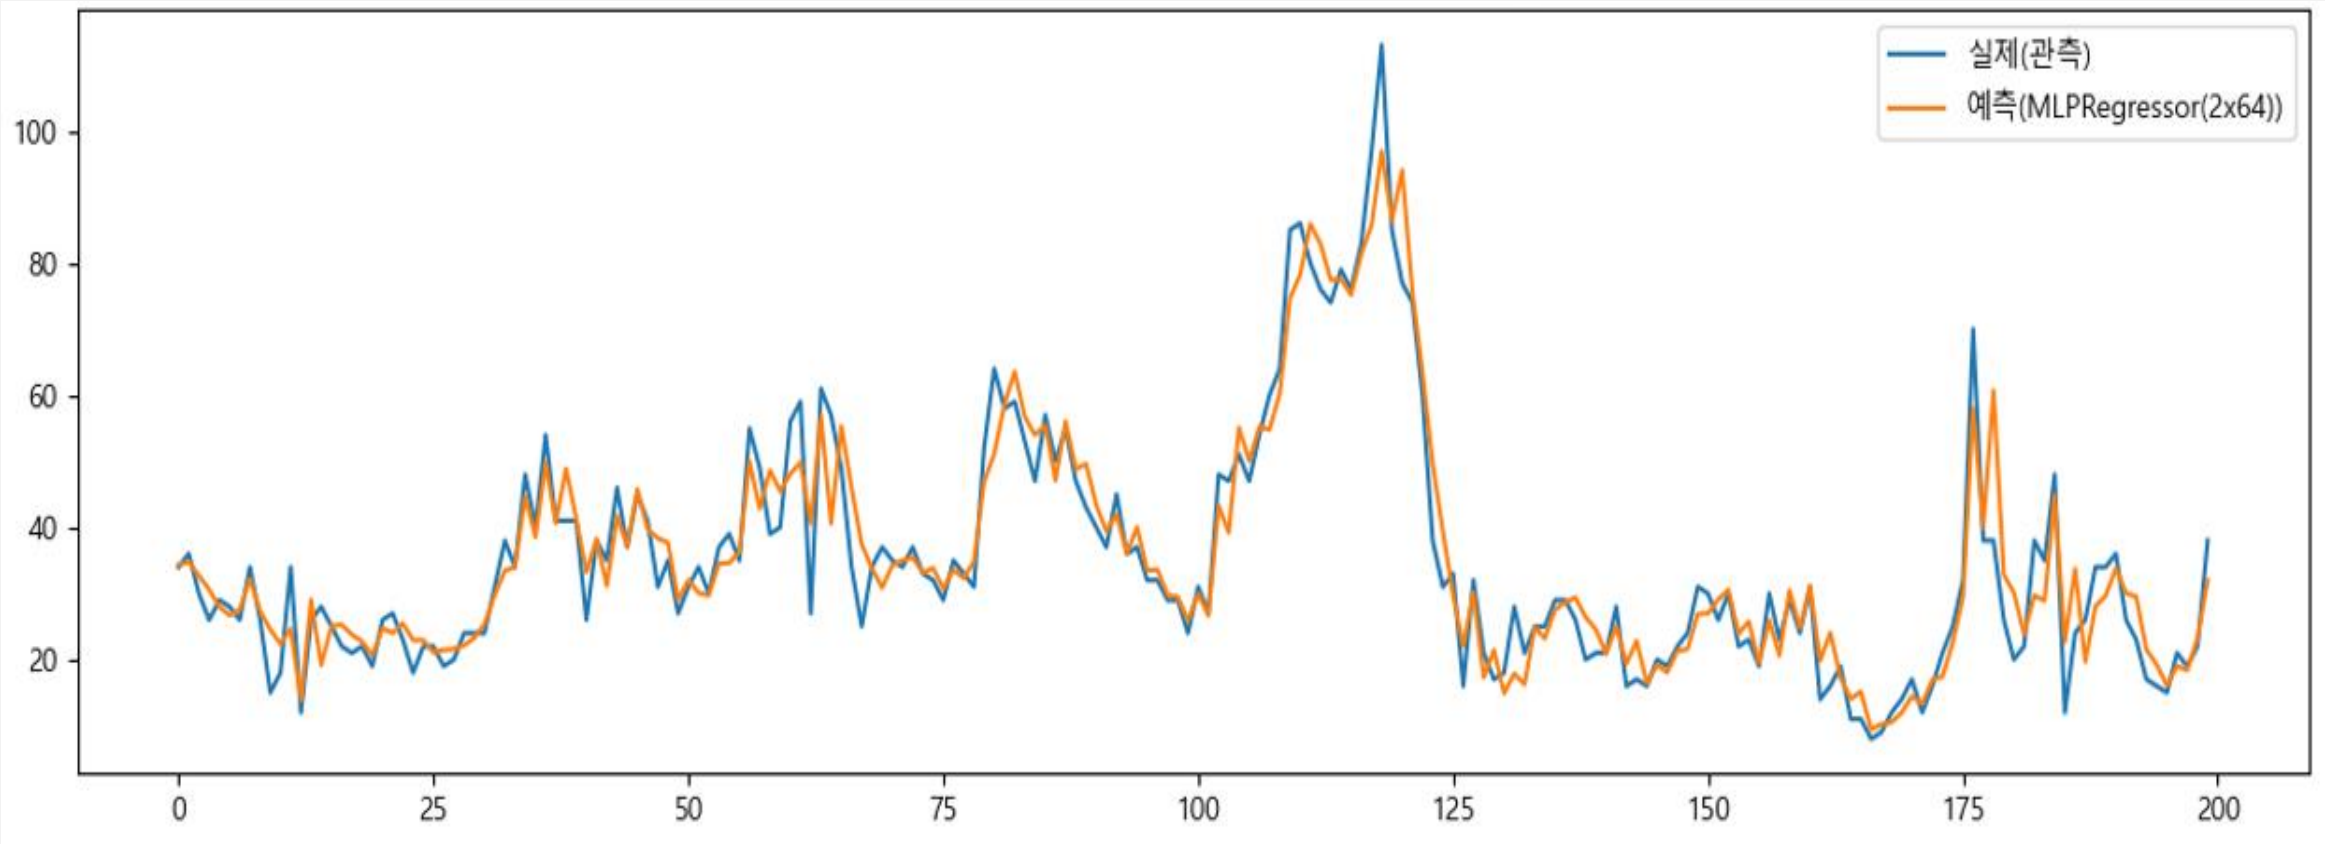

10. 신경망 기반 회귀모델(추가 연구)

선형모델 vs 신경망모델

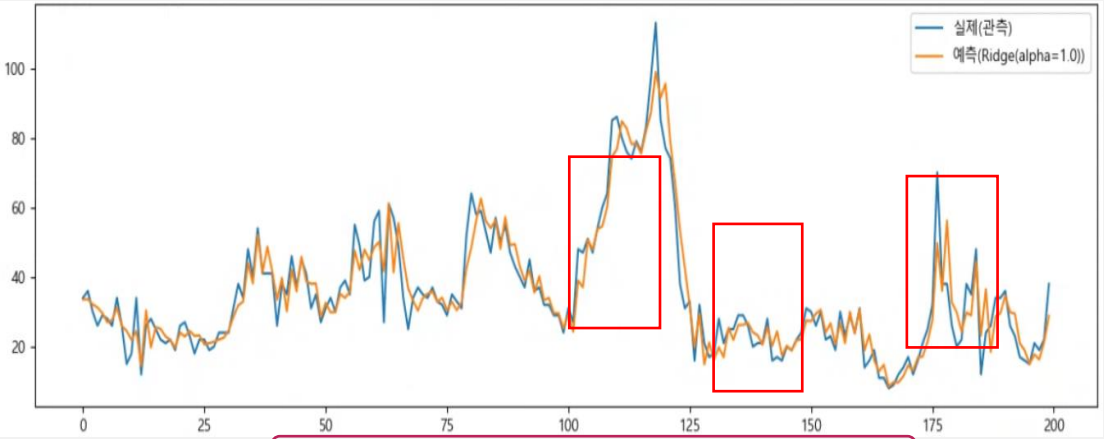

Ridge(α=1.0) – L2

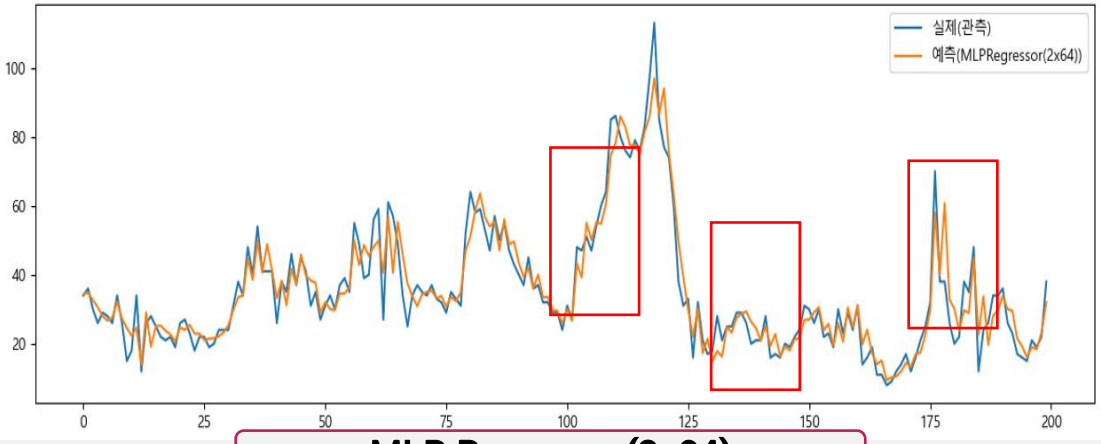

MLP Regressor(2x64)

120~200 구간에서 실제 PM10 급등 : 선형 모델은 완만하게 반응하여 예측 오차 증가

10. 신경망 기반 회귀모델(추가 연구)

- **결론**

- MLPRegressor(2×64)(신경망 모델)은 모든 지역에서 **가장 낮은 RMSE**를 기록하며 최상위 성능을 달성
- 다만, MLP는 학습 시간이 더 길고 구조가 복잡하며 과적합 위험성을 가진다는 점에서, 선형 모델 대비 실용성에 대해 고민할 필요가 있음
- 이번 실험에서는 데이터가 충분히 크고 전처리가 잘 이루어져 MLP가 가장 우수한 결과를 도출하였으나, 고전 선형모델도 안정적인 성능 확인
- MLP는 지역별 미세먼지의 비선형적 패턴까지 포착하여 최저 RMSE를 달성하며 가장 뛰어난 예측 성능을 보임
- 선형 모델은 변화폭이 갑자기 튀는 구간을 따라가기 어려우나 MLP는 일부 더 잘 포착
- 신경망 모델은 학습시간이 길고 과적합 가능성이 있어 무조건 좋은 분석 방법은 아닐 수 있으며, 선형 데이터 분석에서는 오히려 고전적인 분석방법이 시간대비 효율적일 수 있음

* 데이터가 다양하고 정제가 잘 될 수록 **딥러닝**이 아닌 **머신러닝** 기법도 좋은 성능을 발휘할 수 있다.

	station	LinearRegression(RMSE)	Ridge(alpha=1.0)(RMSE)	Lasso(alpha=0.1)(RMSE)	MLPRegressor(2x64)(RMSE)
0	[대전 서구]월평동	5.048329	5.048330	5.196951	4.577483
1	[대전 서구]둔산동	6.206140	6.206139	6.481529	5.822268
2	[충북 청주시]오창읍	5.132852	5.132852	5.307994	4.678235
3	[충북 청주시]봉명동	4.946626	4.946627	5.111690	4.462975

감사합니다.